Многопоточное Программирование: Введение и Мотивация

Роман Елизаров, JetBrains, <u>elizarov@gmail.com</u> Никита Коваль, JetBrains, <u>ndkoval@ya.ru</u>

ИТМО 2020



Базовые правила игры

• Домашние задания

- После каждой (±ε) лекции
- **Yepes GitHub**
- Инструкции будут позже

• Контрольные вопросы

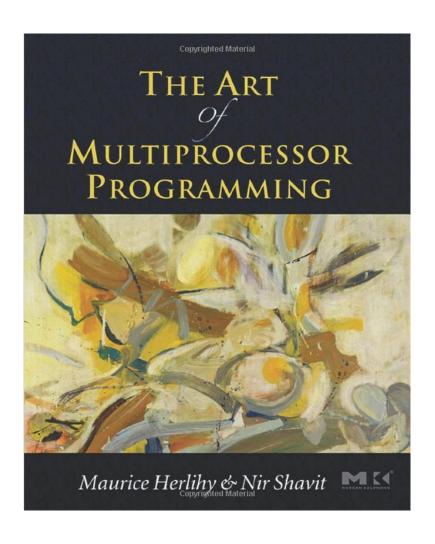
- Для вас, чтобы проверить понимание
- (запаситесь бумагой и ручкой)

• Зачет по предмету

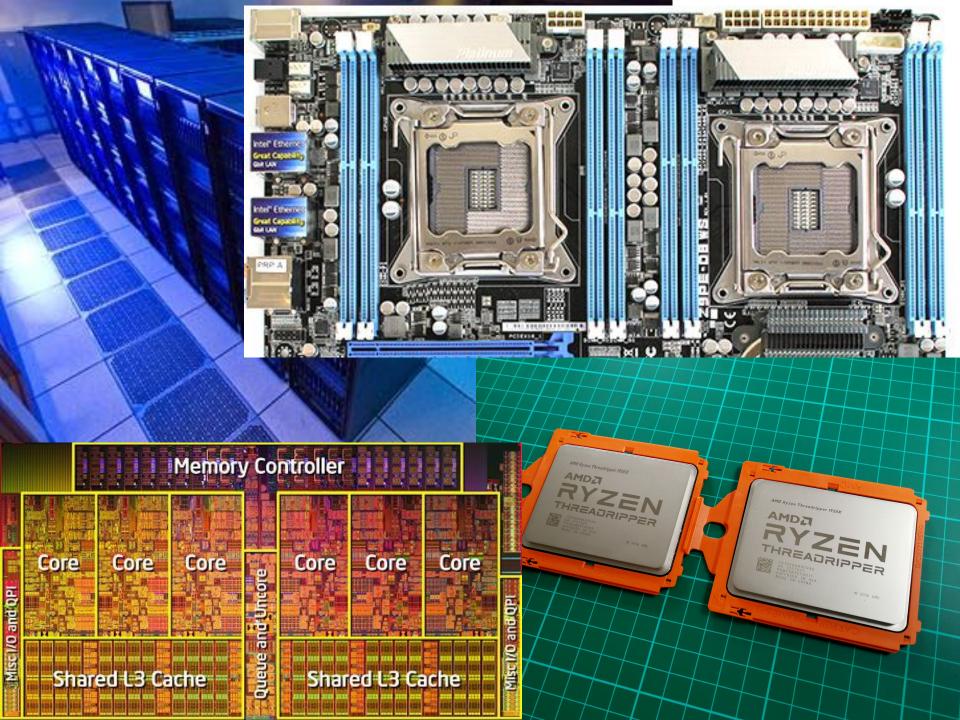
- Сдача всех обязательных ДЗ => Зачет

ЛИТЕРАТУРА

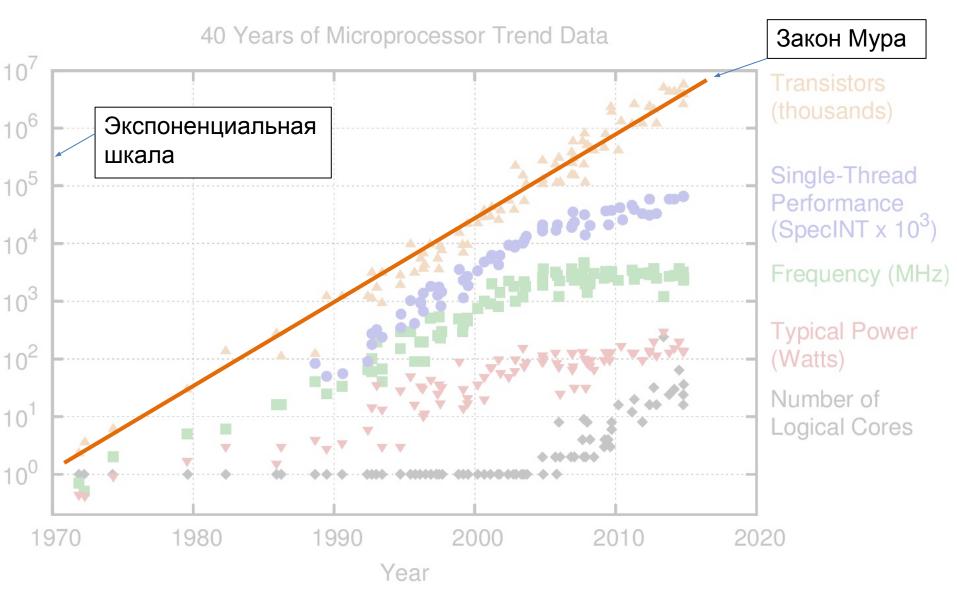
Для самостоятельной подготовки



Зачем нам это?

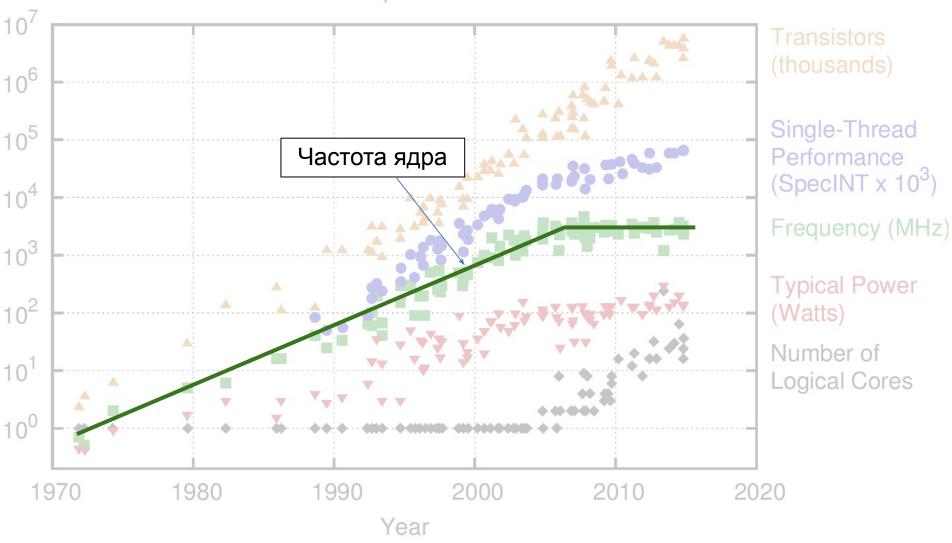


Закон Мура и "The free lunch is over"



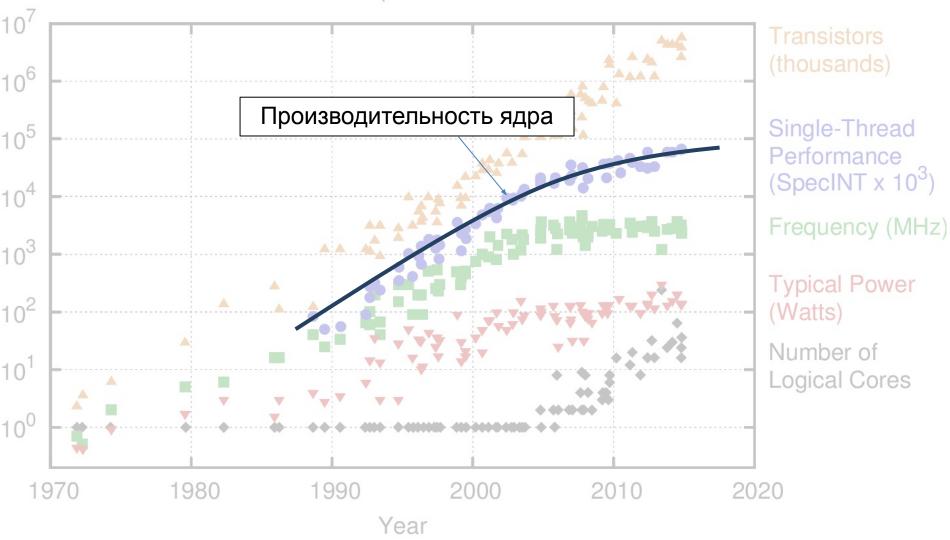
Закон Мура и "The free lunch is over"

40 Years of Microprocessor Trend Data



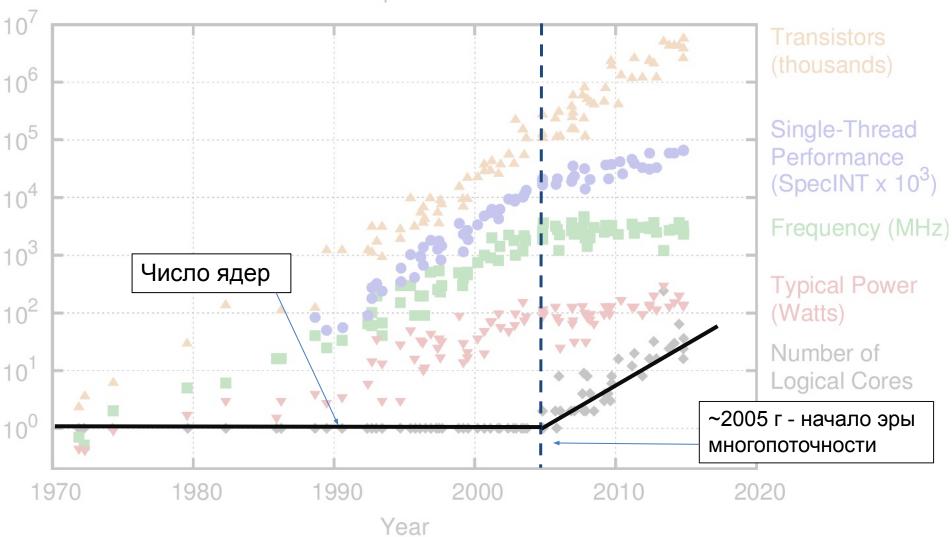
Закон Мура и "The free lunch is over"

40 Years of Microprocessor Trend Data

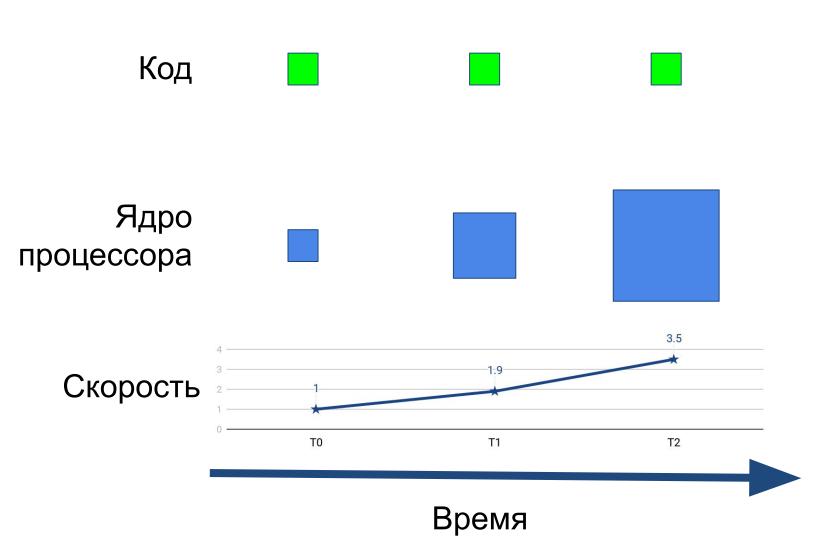


Закон Mypa и "The free lunch is over"

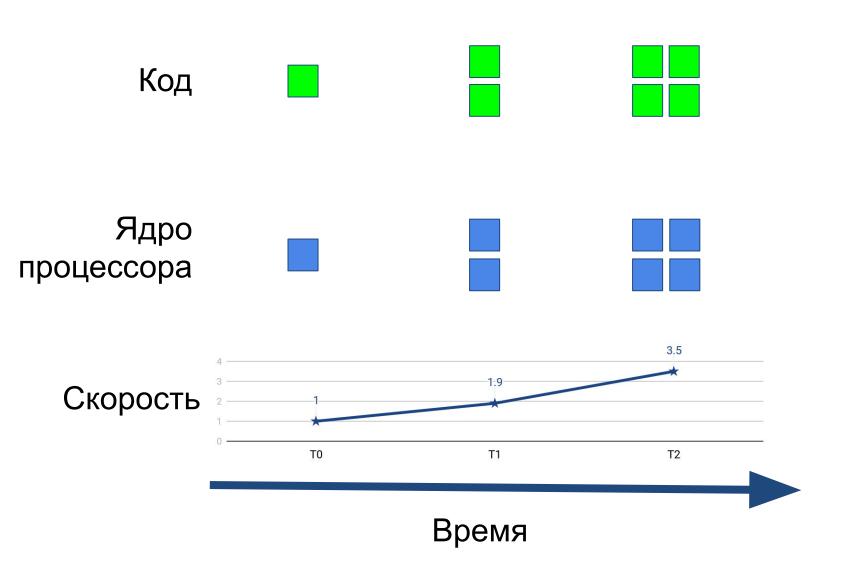
40 Years of Microprocessor Trend Data



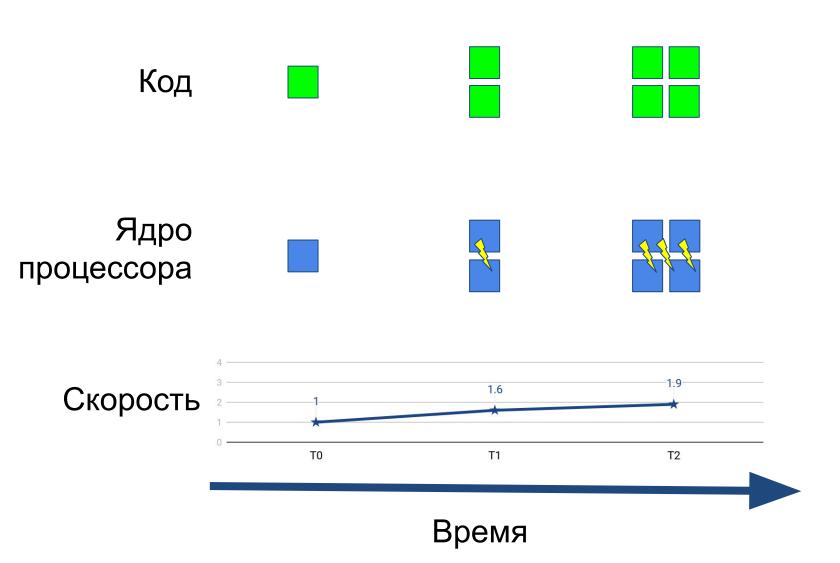
Масштабирование: Закон Мура (традиционное)



Масштабирование: Эра Многопоточности (идеал)



Масштабирование: Эра Многопоточности (реально)

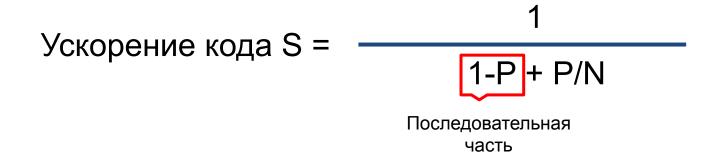


N - число потоков

Ускорение кода S = Время на 1 ядре Время на N ядрах

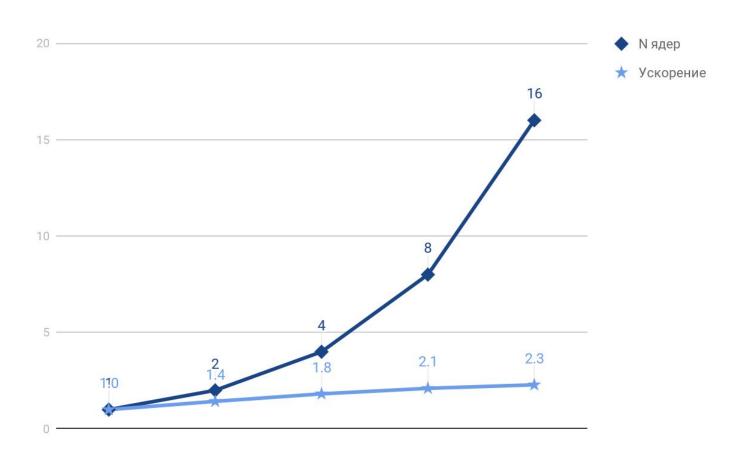
N - число потоков

N - число потоков



N - число потоков

Р - доля параллельного кода = 60%



N - число потоков \rightarrow ∞

Maкс ускорение кода
$$S = \frac{1}{1-P}$$

N - число потоков \rightarrow ∞

Р - доля параллельного кода = 60%

Макс ускорение кода
$$S = \frac{1}{1-P} = 2.5$$

N - число потоков \rightarrow ∞

Р - доля параллельного кода = 95%

Макс ускорение кода
$$S = \frac{1}{1-P} = 20$$

N - число потоков \rightarrow ∞

Р - доля параллельного кода = 99%

Макс ускорение кода
$$S = \frac{1}{1-P} = 100$$

Контрольный вопрос

Некий алгоритм может быть практически полностью выполнен параллельно на разных процессорах, но 5% от всех вычислений все равно должны быть выполнены последовательно. Во сколько раз может увеличиться скорость работы этого алгоритма при запуске его на системе с 16 процессорами вместо системы с 1 процессором?

Для масштабируемости нужно больше параллелизма

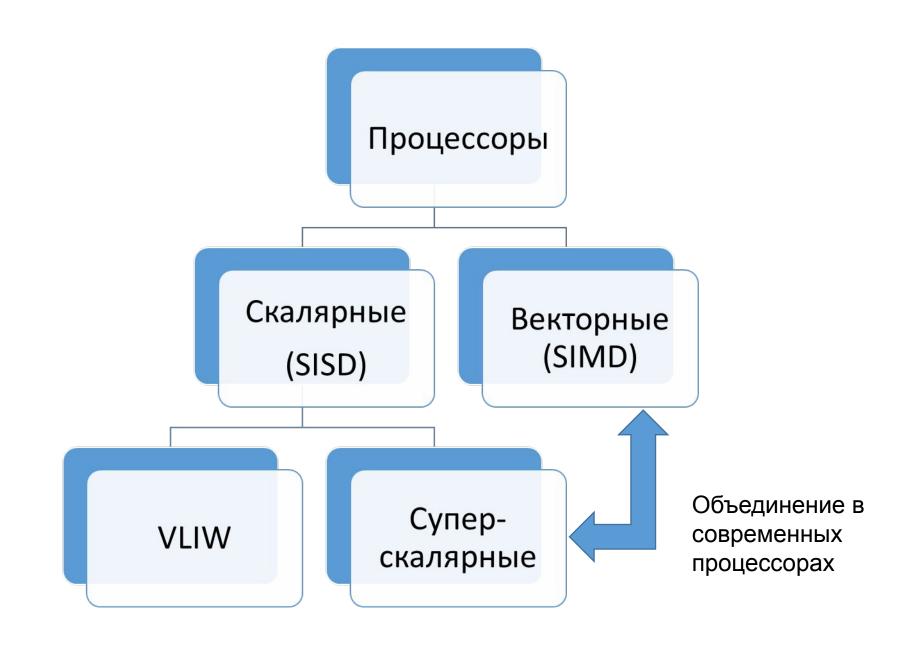
Разные типы параллелизма

Параллелизм на уровне инструкций (ILP – instruction level parallelism)

Нет зависимости по данным: можно выполнить (1) и (2) параллельно

Способы использования ILP:

- Конвейер
- Суперскалярное исполнение
 - Внеочередное исполнение
 - Переименование регистров
 - Спекулятивное исполнение
 - Предсказание переходов
- Длинное машинное слово (VLIW very long instruction word)
- Векторизация (SIMD)

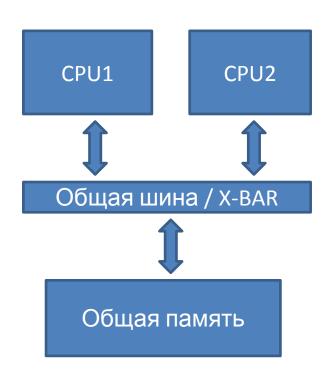


У параллелизма на уровне инструкций есть предел



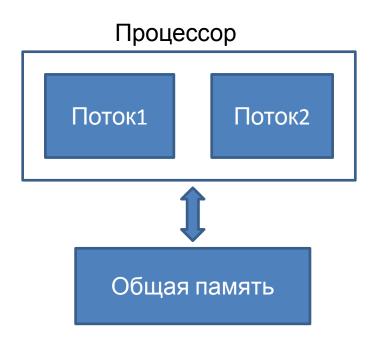
Параллельное программирование

Симметричная мультипроцессорность (SMP – symmetric multiprocessing)



Два (или больше) вычислительных <u>ядра</u>. На каждом свой <u>поток</u> исполняемых инструкций

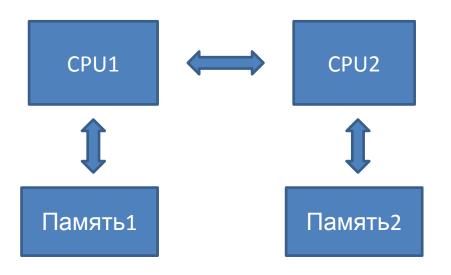
Одновременная многозадачность (SMT – simultaneous multithreading)



Два (или более) **потока** одновременно исполняются одним физическим вычислительным ядром.

Для программиста выглядит как SMP.

Асимметричный доступ к памяти (NUMA – non-uniform memory access)



Модель программирования такая же что и в SMP – **общая память**

Операционные системы

- Типы
 - Однозадачные
 - Система с пакетными заданиями (batch processing)
 - Многозадачные / с разделением времени (time-sharing)
 - Кооперативная многозадачность (cooperative multitasking)
 - Вытесняющая многозадачность (preemptive multitasking)
- История многозадачности
 - Изначально нужно было для раздела одной дорогой машины между разными пользователями
 - Теперь нужно для использования ресурсов одной многоядерной машины для множества задач

Основные понятия в современных ОС

- Процесс владеет памятью и ресурсами
- Поток контекст исполнения внутри процесса
 - В одном процессе может быть несколько потоков
 - Все потоки работают с общей памятью процесса
- Но в теории мы их будем смешивать
 - В научных работах исторически сложилось называть потоки исполнения «процессы» и обозначать большими буквами: P, Q, R...

Контрольный вопрос

- 1. Какие утверждения верные?
- **х** а. В операционной системе всегда выполняет один процесс, но множество потоков может выполняться одновременно.
- ✓ b. Внутри одного процесса может работать множество потоков.
- с. Каждый процесс имеет свою собственную область памяти, отличную от памяти других процессов.

Формализм

Нужна формальная модель параллельных вычислений

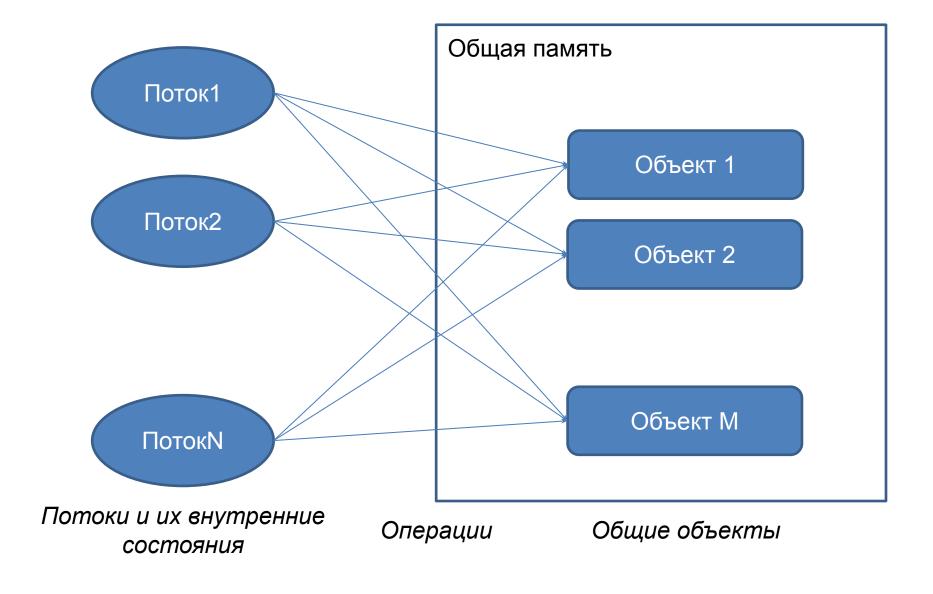
- Чтобы доказывать:
 - корректность алгоритмов
 - невозможность построения тех или иных алгоритмов
 - минимально-необходимые требования для тех или иных алгоритмов
- Для формализации отношений между прикладным программистом и разработчиком компилятора и системы исполнения кода



Модели программирования

- «Классическое» однопоточное / однозадачное
 - Можем использовать ресурсы многоядерной системы только запустив множество разных, независимых задач
- Многозадачное программирование
 - Возможность использовать ресурсы многоядерной системы в рамках решения одной задачи
 - Варианты:
 - Модель с общей памятью
 - Модель с передачей сообщений (распределенное программирование)

Модель с общими объектами (общей памятью)



Общие объекты

- Потоки выполняют операции над общими, разделяемыми объектами
- В этой модели не важны операции внутри потоков:
 - Вычисления
 - Обновления регистров процессора
 - Обновления стека потока
 - Обновления любой другой локальной для потока памяти
- Важна только коммуникация между потоками
- В этой модели единственный тип коммуникации между потоками – это работа с общими объектами

Общие переменные

- **Общие переменные** это просто простейший тип общего объекта:
 - У него есть значение определенного типа
 - Есть операция чтения (read) и записи (write).
- Общие переменные это базовые строительные блоки для многопоточных алгоритмов
- Модель с общими переменными это хорошая абстракция современных многопроцессорных систем и многопоточных ОС
 - На практике, это область памяти *процесса*, которая одновременно доступна для чтения и записи всем *потокам*, исполняемым в данном процессе

Свойства многопоточных программ

- Последовательные программы детерминированы
 - Если нет явного использования случайных чисел и другого общения с недетерминированным внешним миром
 - Их свойства можно установить, анализируя последовательное исполнение при данных входных параметрах
- Многопоточные программы в общем случае недетерминированы
 - Даже если код каждого потока детерминирован
 - Результат работы зависит от фактического **исполнения** при данных входных параметрах
 - А этих исполнений может быть много
- Говорим «**программа A имеет свойство P**», если *программа A имеет свойство P при любом исполнении*

Как моделировать многопоточное выполнение?

- **ПРИМЕР:** Очень простая программа. Всего два потока (Р и Q), каждый из которых последовательно выполняет 2 действия и останавливается
 - У них есть общие переменные х и у (в начале равные 0)
 - И у каждого есть по одной локальной переменной (r1 в P, r2 в Q)
 - Какие есть варианты r1 и r2 после завершения исполнения?

shared int x = 0, y = 0

thread P:

$$1: x = 1$$

$$2: r1 = y$$

3: stop

thread Q:

$$2: r2 = x$$

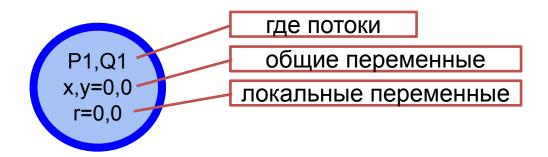
Пример



1: x = 1

2: r1 = y

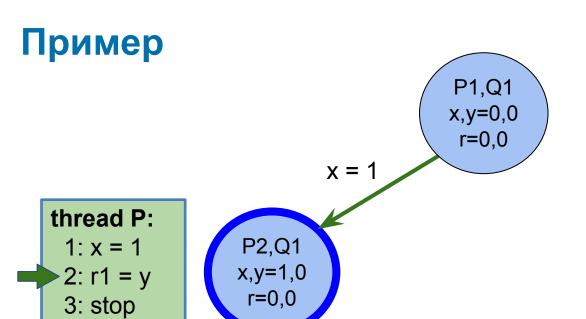
3: stop



thread Q:

1: y = 1

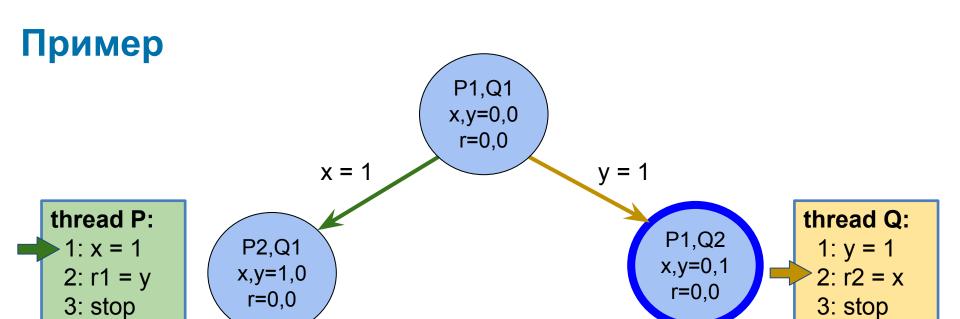
2: r2 = x



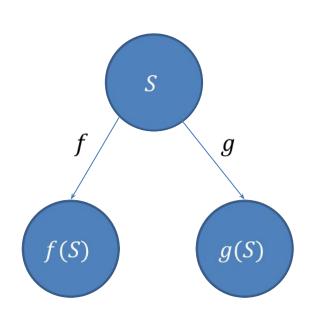
thread Q:

1: y = 1

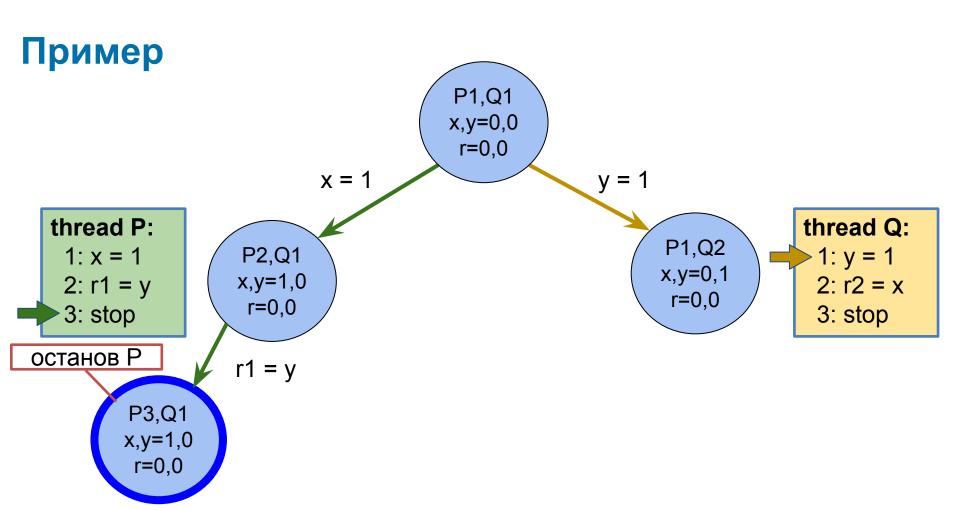
2: r2 = x

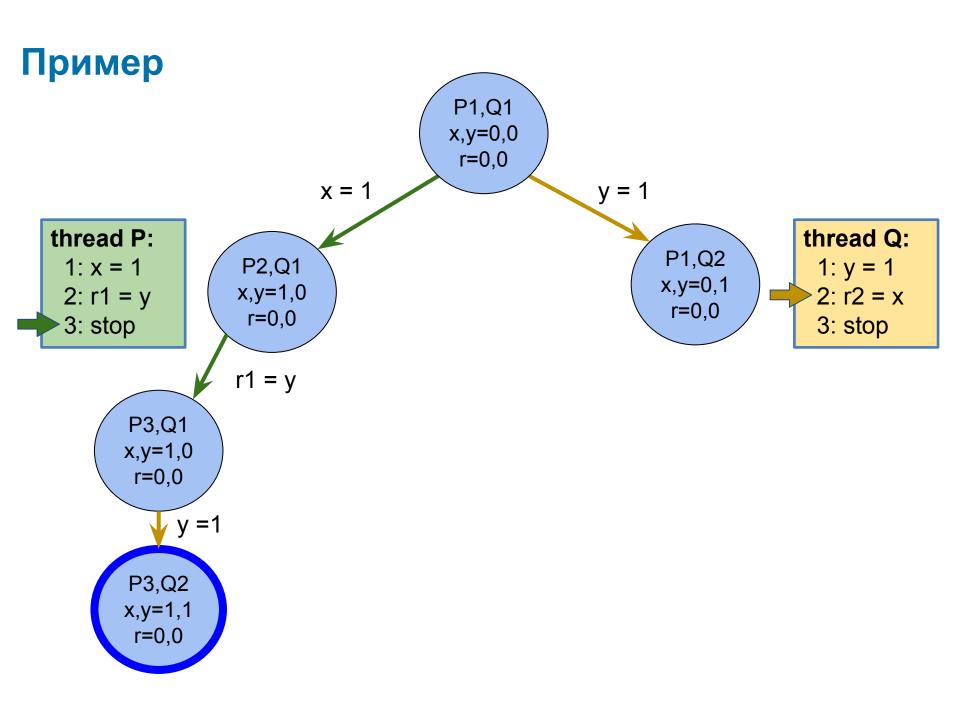


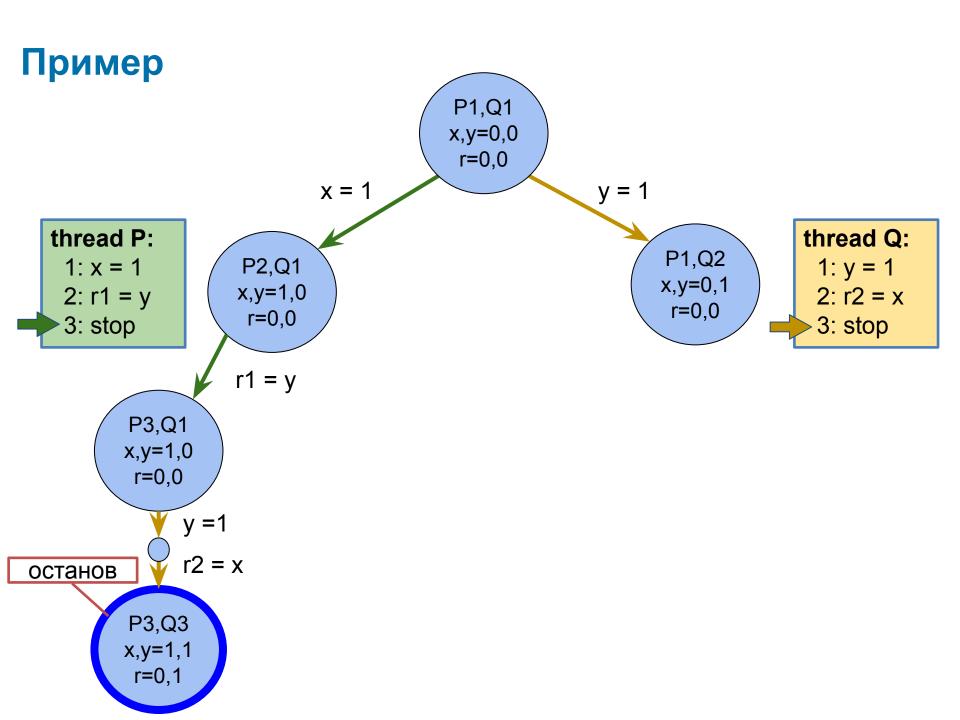
Моделирование исполнений через чередование операций

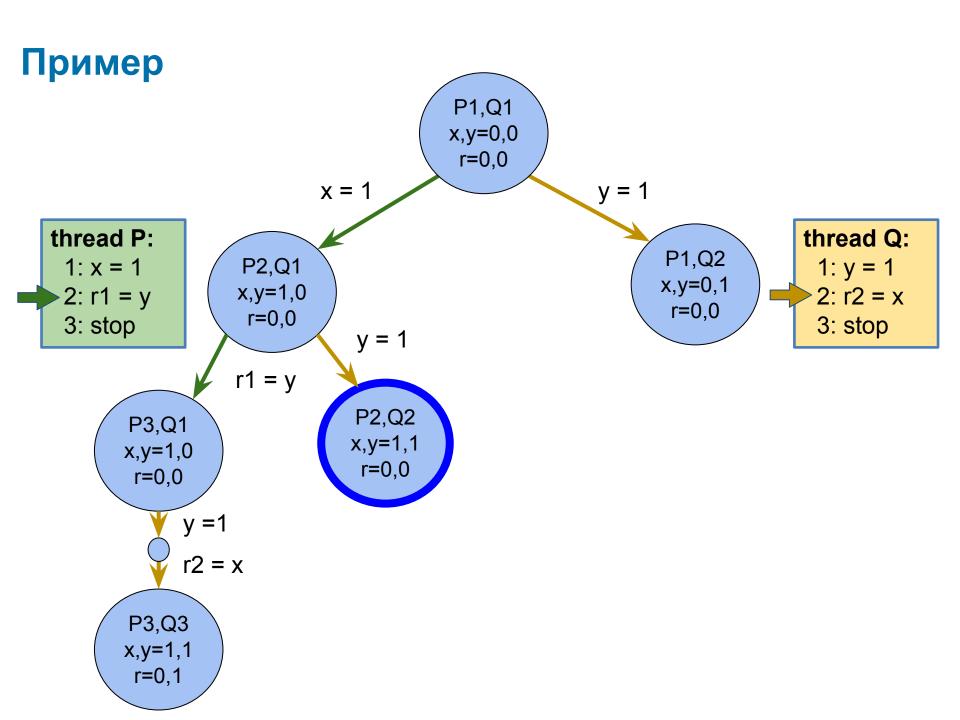


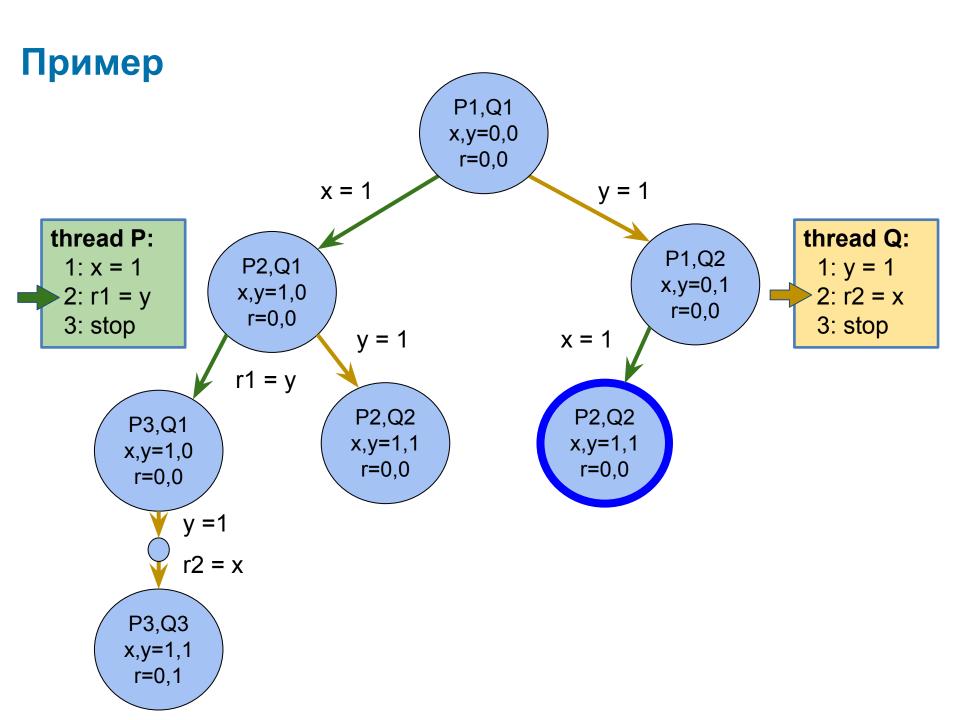
- *S* это **общее состояние**:
 - Состояние всех потоков (IP+locals)
 - И состояние всех [общих] объектов
- *f* и *g* это **операции**
 - Количество возможных операций в каждом состоянии равно количеству потоков
- f(S) это новое состояние после применения операции f в состоянии S

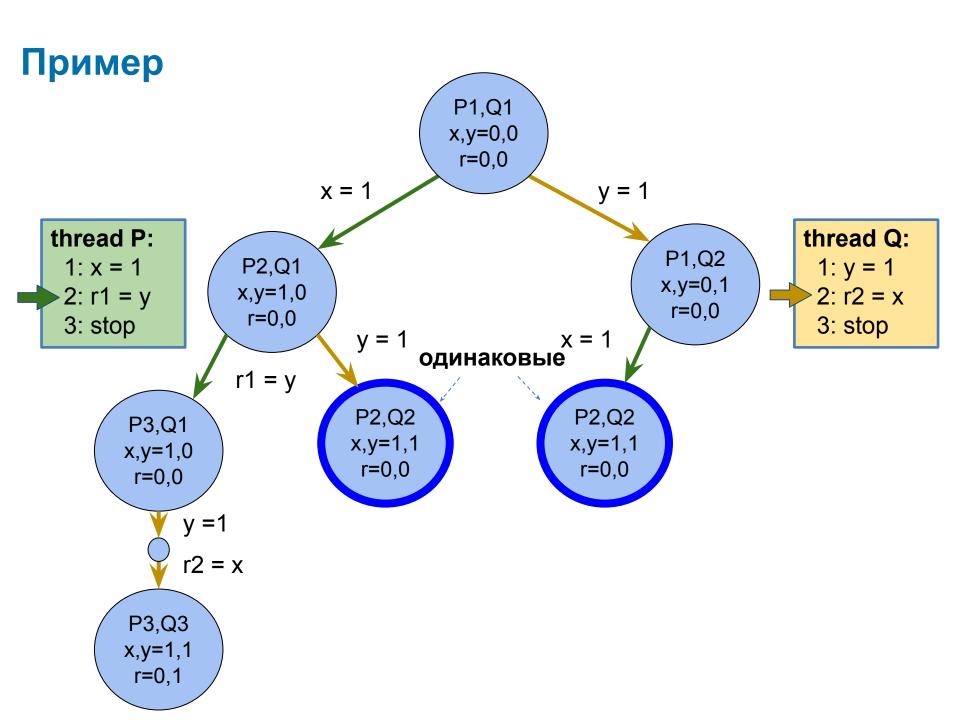


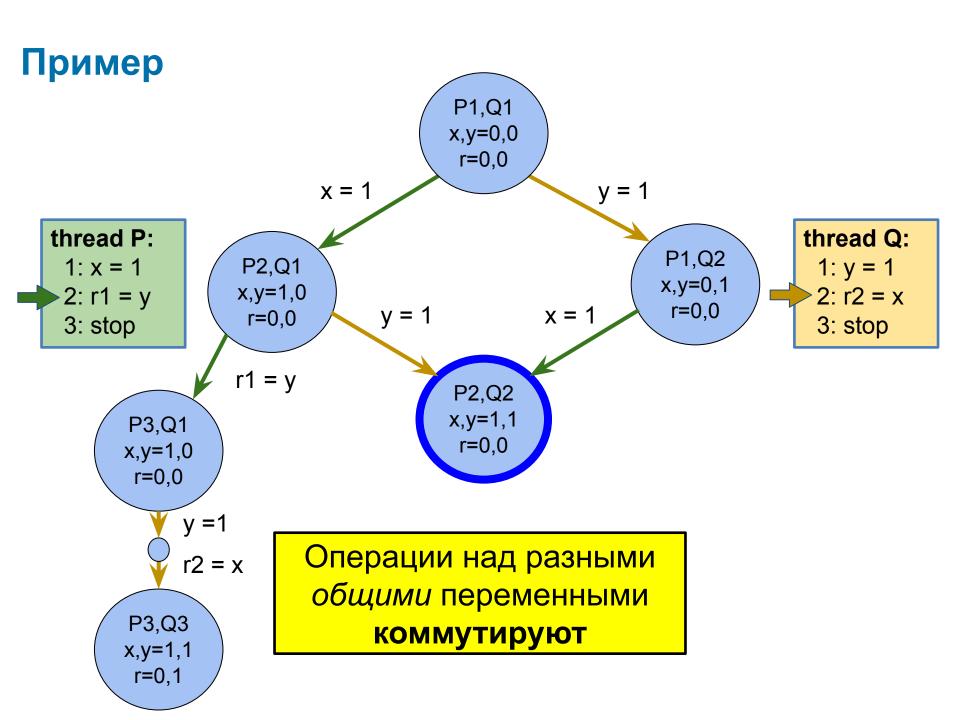


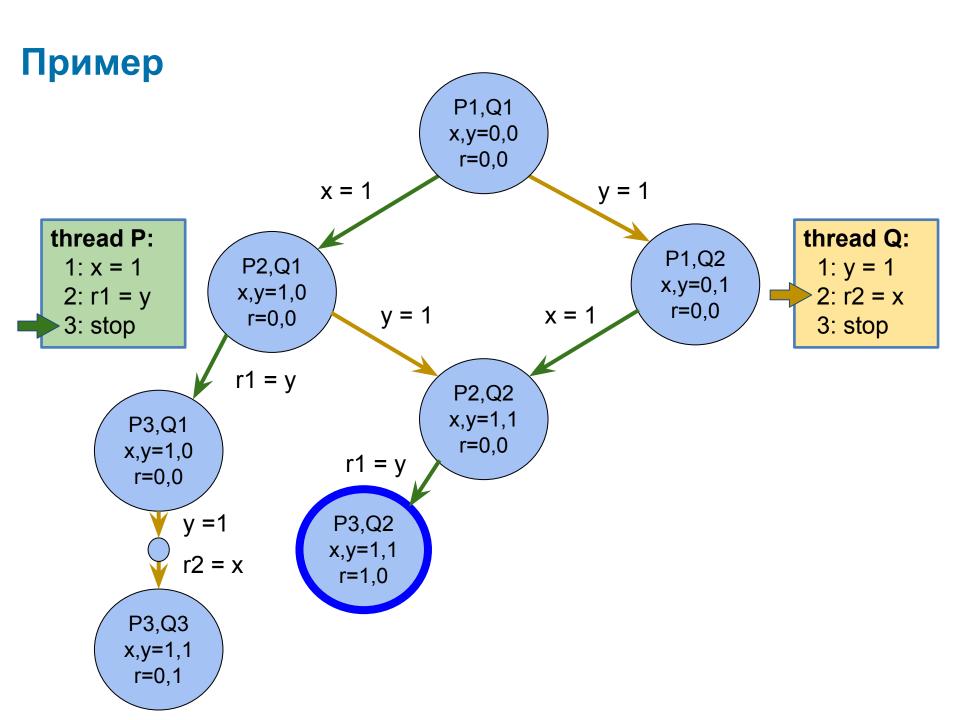


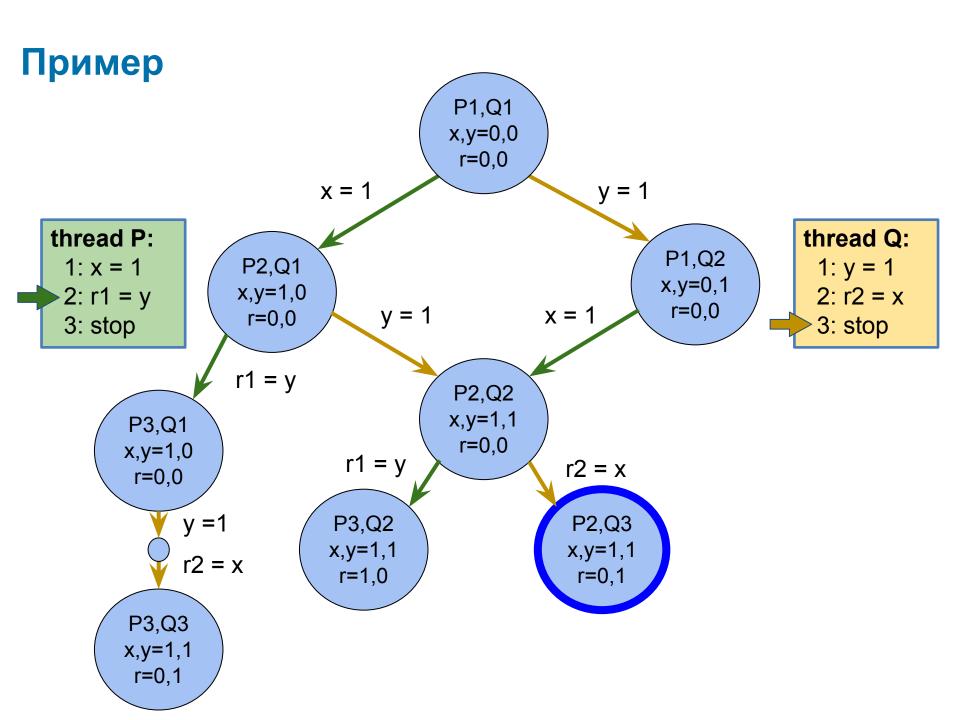


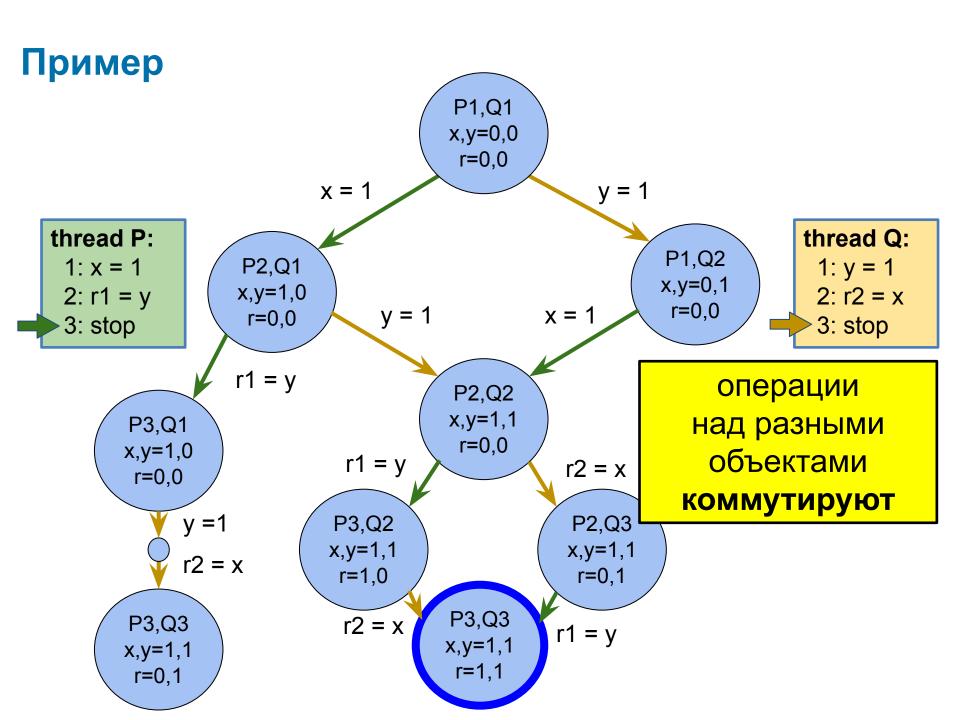


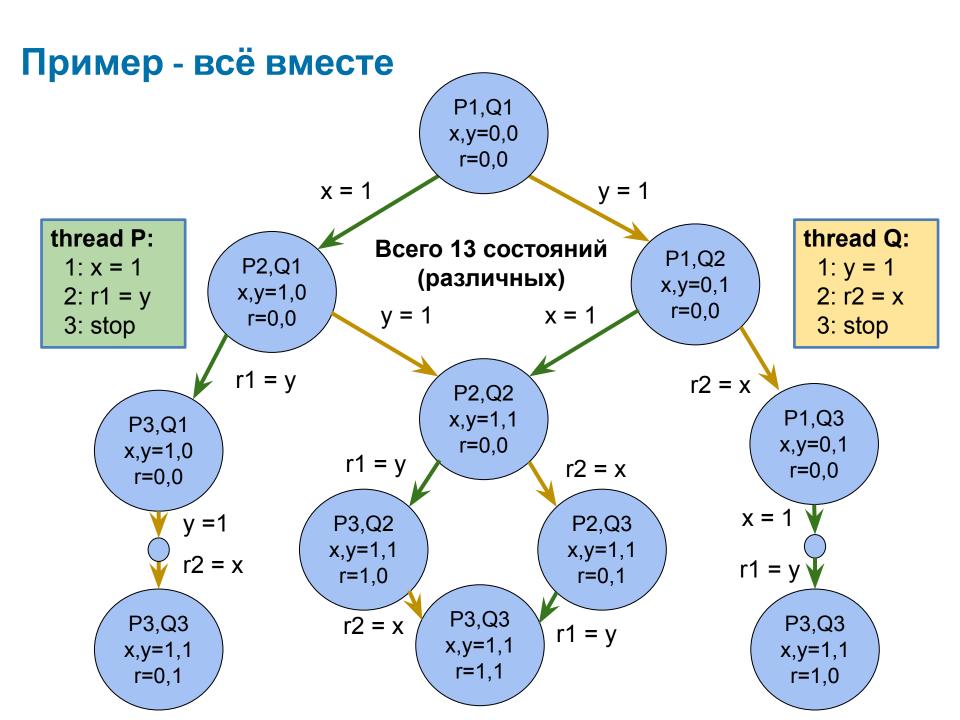


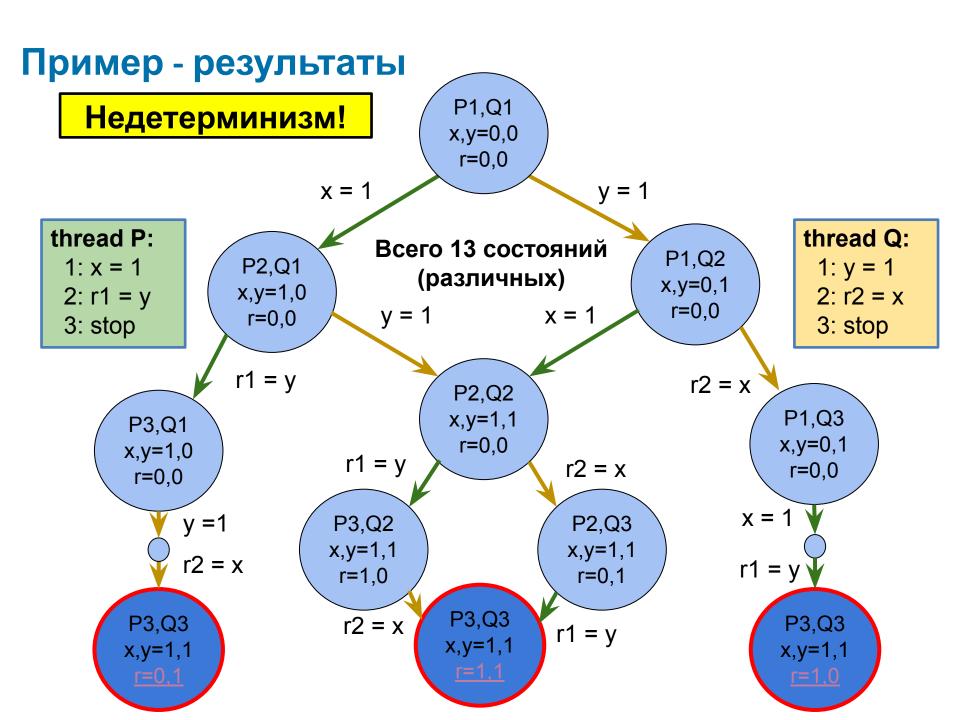












```
@JCStressTest
@State
@Outcome(id = "0, 1", expect = Expect.ACCEPTABLE)
@Outcome(id = "1, 1", expect = Expect.ACCEPTABLE)
@Outcome(id = "1, 0", expect = Expect.ACCEPTABLE)
public class SimpleTest1 {
   int x;
   int y;
   @Actor
   public void threadP(IntResult2 r) {
       x = 1;
       r.r1 = y;
   @Actor
   public void threadQ(IntResult2 r) {
       \mathbf{v} = 1;
       r.r2 = x;
```

```
@JCStressTest
@State
@Outcome(id = "0, 1", expect = Expect.ACCEPTABLE)
@Outcome (id = "1, 1", expect = Expect.ACCEPTABLE)
@Outcome(id = "1, 0", expect = Expect.ACCEPTABLE)
public class SimpleTest1 {
   int x;
   int y;
   @Actor
   public void threadP(IntResult2 r) {
       x = 1;
       r.r1 = y;
   @Actor
   public void threadQ(IntResult2 r) {
      y = 1;
       r.r2 = x;
```

```
@JCStressTest
@State
@Outcome(id = "0, 1", expect = Expect.ACCEPTABLE)
@Outcome (id = "1, 1", expect = Expect.ACCEPTABLE)
@Outcome(id = "1, 0", expect = Expect.ACCEPTABLE)
public class SimpleTest1 {
   int x;
   int y;
   @Actor
   public void threadP(IntResult2 r) {
      x = 1;
       r.r1 = y;
   @Actor
   public void threadQ(IntResult2 r) {
      y = 1;
       r.r2 = x;
```

```
@JCStressTest
@State
@Outcome(id = "0, 1", expect = Expect.ACCEPTABLE)
@Outcome (id = "1, 1", expect = Expect.ACCEPTABLE)
@Outcome(id = "1, 0", expect = Expect.ACCEPTABLE)
public class SimpleTest1 {
   int x;
   int y;
   @Actor
   public void threadP(IntResult2 r) {
       \mathbf{x} = 1;
       r.r1 = y;
   @Actor
   public void threadQ(IntResult2 r) {
       \mathbf{v} = 1;
       r.r2 = x;
```

```
@JCStressTest
@State
@Outcome(id = "0, 1", expect = Expect.ACCEPTABLE)
@Outcome(id = "1, 1", expect = Expect.ACCEPTABLE)
@Outcome(id = "1, 0", expect = Expect.ACCEPTABLE)
public class SimpleTest1 {
   int x;
   int y;
   @Actor
   public void threadP(IntResult2 r) {
       \mathbf{x} = 1;
       r.r1 = y;
   @Actor
   public void threadQ(IntResult2 r) {
       \mathbf{v} = 1;
       r.r2 = x;
```

Запустим!

```
@JCStressTest
@State
@Outcome(id = "0, 1", expect = Expect.ACCEPTABLE)
@Outcome(id = "1, 1", expect = Expect.ACCEPTABLE)
@Outcome(id = "1, 0", expect = Expect.ACCEPTABLE)
public class SimpleTest1 {
   int x;
   int y;
   @Actor
   public void threadP(IntResult2 r) {
       \mathbf{x} = 1;
       r.r1 = y;
   @Actor
   public void threadQ(IntResult2 r) {
       \mathbf{v} = 1;
       r.r2 = x;
```

Запустим!

```
[FAILED] SimpleTest1

State Occurrences

0, 0 54,186,890

0, 1 74,036,686

1, 0 53,219,852

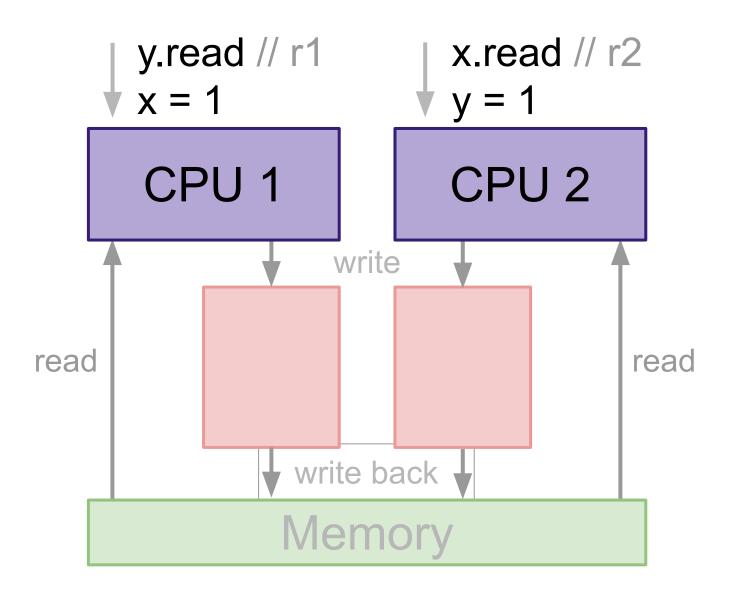
1, 1 372
```

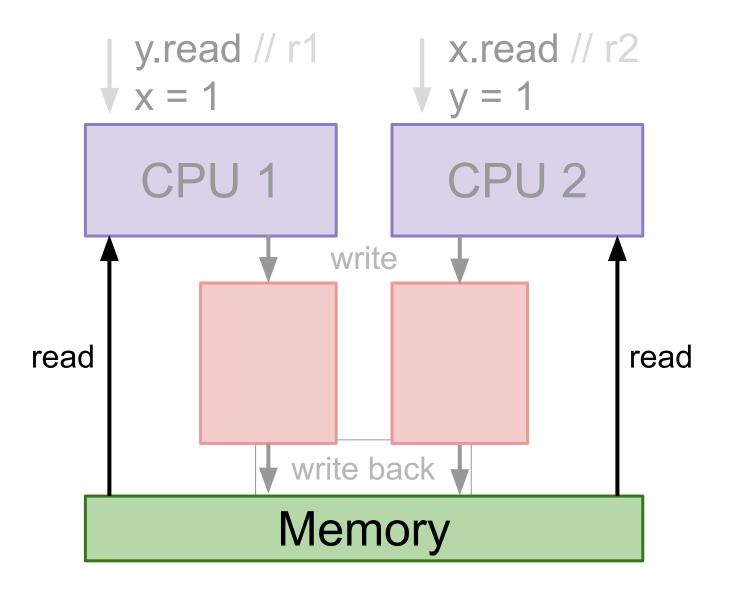
```
@JCStressTest
@State
@Outcome(id = "0, 1", expect = Expect.ACCEPTABLE)
@Outcome(id = "1, 1", expect = Expect.ACCEPTABLE)
@Outcome(id = "1, 0", expect = Expect.ACCEPTABLE)
public class SimpleTest1 {
   int x;
   int y;
   @Actor
   public void threadP(IntResult2 r) {
       x = 1;
       r.r1 = y;
   @Actor
   public void threadQ(IntResult2 r) {
       \mathbf{v} = 1;
       r.r2 = x;
```

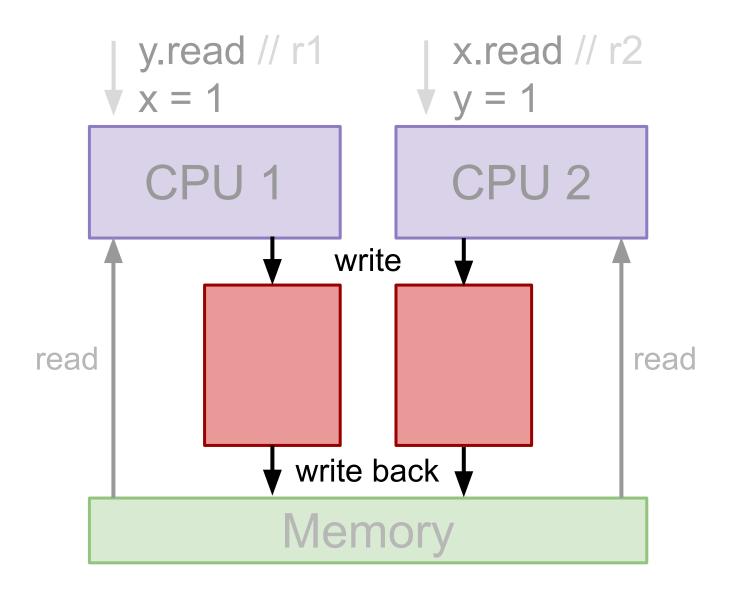
Запустим!

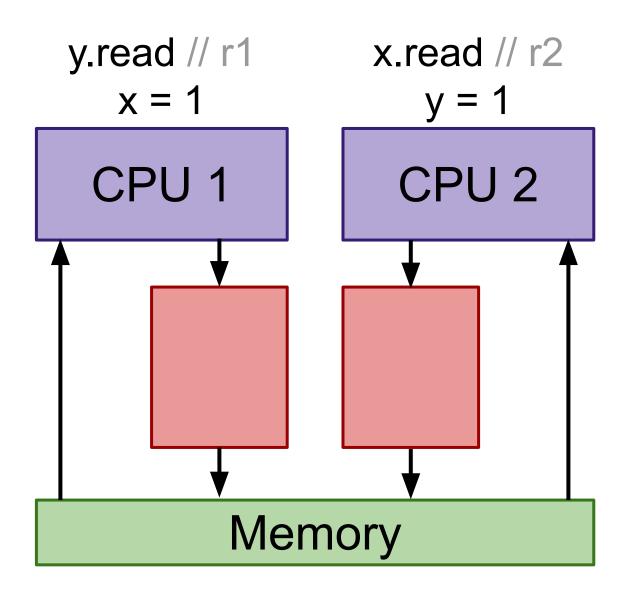
[FAILED]	SimpleTest1		
State	Occurrences		
0, 0	54 , 186 , 890		
0, 1	74,036,686		
1, 0	53,219,852		
1, 1	372		

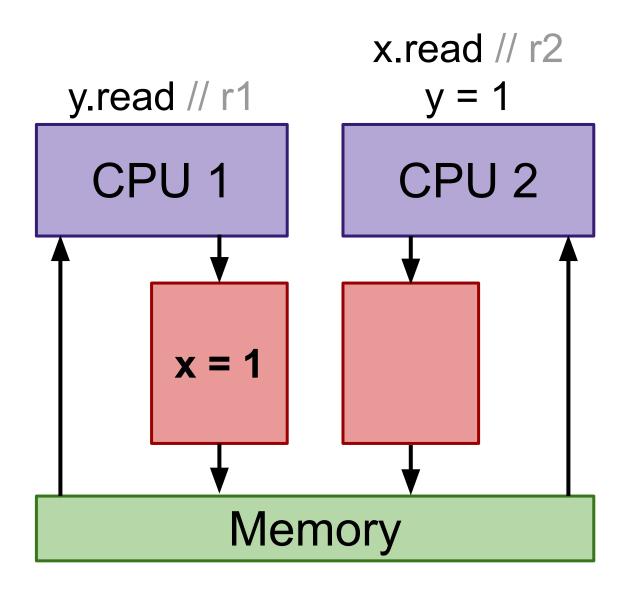
Как же так? Ведь пары r=0,0 вообще не должно было быть!

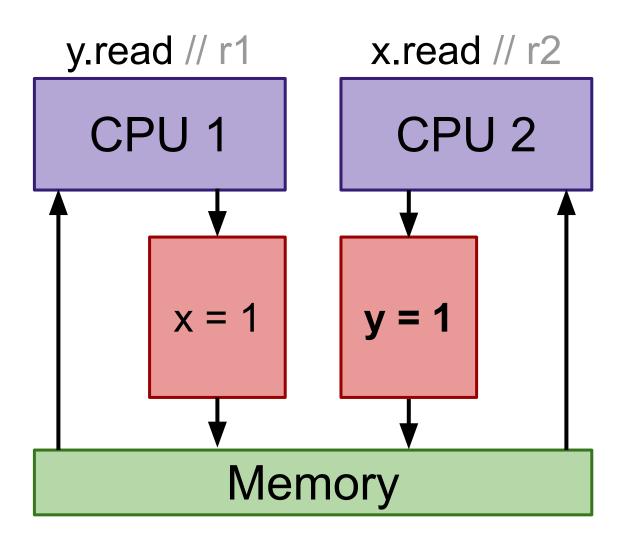


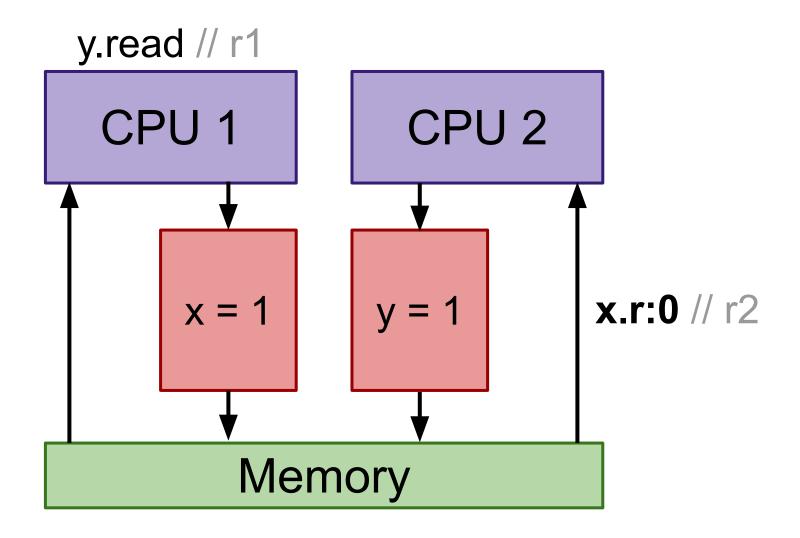


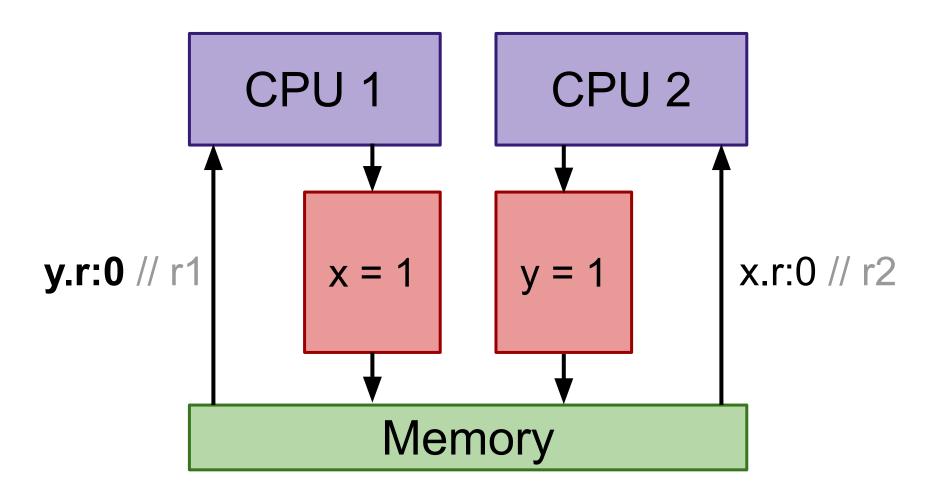












Практическое объяснение

- Запись на современных процессорах не сразу идет в память
 - Буферы записей на x86 (TSO)
 - Еще хуже на ARM
- => Другой поток не увидит эту запись сразу

Практическое объяснение

- Запись на современных процессорах не сразу идет в память
 - Буферы записей на x86 (TSO)
 - Еще хуже на ARM
- => Другой поток не увидит эту запись сразу
- А еще компилятор мог переставить инструкции!

shared int $\mathbf{x} = 0$, $\mathbf{y} = 0$		 shared int $\mathbf{x} = 0$, $\mathbf{y} = 0$	
Thread P:	Thread Q:	Thread P:	Thread Q:
x = 1	y = 1	r1 = y	r2 = x
r1 = y	r2 = x	x = 1	y = 1

Философия модели чередования

- Модель чередования не «параллельна»
 - Все операции в ней происходят последовательно (только порядок заранее не задан)
- А на самом деле на реальных процессорах операции чтения и записи памяти **не мгновенные**. Они происходят <u>параллельно</u> как в разных ядрах так и внутри одного ядра
 - И вообще процессор обменивается с памятью сообщениями чтения/записи и таких сообщений находящихся в обработке одновременно может быть очень много (!)

Модель чередования не отражает фактическую реальность. Когда же её можно использовать?

Контрольный вопрос

Какие пары значений х и у возможны после параллельного выполнения следующего кода (Р и Q – потоки, х и у общие переменные) в модели чередования

shared int x = 0, y = 0

thread P:

1: **if** y != 0:

2: x = 42

3: stop

thread Q:

1: **if** x != 0:

2: y = 42